

確率と統計 第9回

正規分布を使いこなす

6月15日

Table of contents

§1 正規分布モデル

§2 Z スコアを用いた標準化

§3 片側確率を求める

§4 68:95:99.7 ルール

ありふれた変数の分布

この世でもっとありふれた分布とはどのような分布だろうか.

ありふれた変数の分布


この世でもっとありふれた分布とはどのような分布だろうか.

例えばある県の成人男性の身長を変数 X としてその分布を記録する. このときその分布を表す図は以下のようなになるだろう:

ありふれた変数の分布



この世でもっとありふれた分布とはどのような分布だろうか.

例えばある県の成人男性の身長を変数 X としてその分布を記録する. このときその分布を表す図は以下のようなになるだろう:




正規分布モデル

上記のような分布を**正規分布**という。正規分布は常に左右対称で、単峰で、釣鐘型の曲線だ。



正規分布モデル



上記のような分布を**正規分布**という。正規分布は常に左右対称で、単峰で、釣鐘型の曲線だ。



現実にある多くの変数はほぼ正規分布に従っているが、厳密に正規分布に従っている変数は存在しない。これは完全に厳密な三角形が現実には存在しないことと似ている。

正規分布モデル

三角形が三辺の長さで一つに定まるように、正規分布も **平均** と **標準偏差** という 2 つのパラメータを決めると一つに定まる。



正規分布モデル

三角形が三辺の長さで一つに定まるように, 正規分布も **平均**と**標準偏差**という 2つのパラメータを決めると一つに定まる.

そこで平均が μ で標準偏差が σ の正規分布を $N(\mu, \sigma)$ と表記する.

正規分布モデル

三角形が三辺の長さで一つに定まるように, 正規分布も **平均**と**標準偏差**という 2つのパラメータを決めると一つに定まる.

そこで平均が μ で標準偏差が σ の正規分布を $N(\mu, \sigma)$ と表記する.

例えば, 平均が 0 で標準偏差が 1 の標準正規分布を以下のように表記する:

正規分布モデル

三角形が三辺の長さで一つに定まるように、正規分布も **平均** と **標準偏差** という 2 つのパラメータを決めると一つに定まる。

そこで平均が μ で標準偏差が σ の正規分布を $N(\mu, \sigma)$ と表記する。

例えば、平均が 0 で標準偏差が 1 の標準正規分布を以下のように表記する：



$N(0, 1)$ または $N(\mu = 0, \sigma = 1)$.

例題: 正規分布の表記

次の正規分布を短縮形で書き記しなさい.

例題: 正規分布の表記

次の正規分布を短縮形で書き記しなさい.

- (a) 平均 5 および標準偏差 3
- (b) 平均-100 および標準偏差 100
- (c) 平均-100 および 分散 100

例題: SAT と ACT

下の表は SAT と ACT の総合スコアの平均と標準偏差を示している. SAT と ACT のスコアの分布はどちらも正規分布に近い. アンのスコアが 1300 でトムのスコアが 24 だったとすると, どちらの成績が良いだろうか.

sat_and_act



	SAT	ACT
平均	1100	21
標準偏差	200	6

例題: SAT と ACT

アンとトムのスコアの位置はそれぞれ次のようになる:



例題: SAT と ACT

アンとトムのスコアの位置はそれぞれ次のようになる:



例題: SAT と ACT


アンとトムのスコアの位置はそれぞれ次のようになる:



アンとトムのスコアがそれぞれどれだけ平均から離れているか, 平均との差と標準偏差との割合で計算すると...

例題: SAT と ACT

アンとトムのスコアの位置はそれぞれ次のようになる:



アンとトムのスコアがそれぞれどれだけ平均から離れているか, 平均との差と標準偏差との割合で計算すると...

$$\frac{1300 - 1100}{200} = 1 > \frac{24 - 21}{6} = 0.5$$

よって, Ann の成績の方がよい.

Zスコアを用いた標準化

平均 μ , 標準偏差 σ の分布に従う観測値 x のZスコアを以下の式で定義する:

Zスコアを用いた標準化

平均 μ , 標準偏差 σ の分布に従う観測値 x のZスコアを以下の式で定義する:

$$Z = \frac{x - \mu}{\sigma}.$$

Zスコアを用いた標準化

平均 μ , 標準偏差 σ の分布に従う観測値 x のZスコアを以下の式で定義する:

$$Z = \frac{x - \mu}{\sigma}.$$

つまり Zスコアは観測値 x が平均 μ から標準偏差 σ の何倍離れているかを表す.

Zスコアを用いた標準化

平均 μ , 標準偏差 σ の分布に従う観測値 x のZスコアを以下の式で定義する:

$$Z = \frac{x - \mu}{\sigma}.$$

つまり Zスコアは観測値 x が平均 μ から標準偏差 σ の何倍離れているかを表す.


Zスコアを計算することによって素点 x の分布における相対的な位置が分かる.

例題: フクロギツネの頭長

フクロギツネの頭長は平均 92.6mm, 標準偏差 3.6mm の正規分布に従っている. 頭長が 95.4mm と 85.8mm のフクロギツネの Z スコアを求めよ. またどちらの値がより観測されにくいかな.


片側確率とは

下図のように色塗りした部分のグラフ全体の面積に占める割合は**下側確率** $P(X \leq x_0)$ (観測値 x が x_0 以下である確率) を表す.




片側確率とは

下図のように色塗りした部分のグラフ全体の面積に占める割合は**下側確率** $P(X \leq x_0)$ (観測値 x が x_0 以下である確率) を表す.



このとき**上側確率** $P(X \geq x_0)$ は $1 - P(X \leq x_0)$ によって求まる.



片側確率の求め方 (正規分布の場合)

いつでもまずは分布の図を描き, 値を入れ, 対応する領域を塗りつぶす. 次にその図から求める確率を確認する. そして対応する Z スコアを計算して確率を求める.

片側確率の求め方 (正規分布の場合)

いつでもまずは分布の図を描き, 値を入れ, 対応する領域を塗りつぶす. 次にその図から求める確率を確認する. そして対応する Z スコアを計算して確率を求める.

Z スコアから片側確率を求める方法には以下がある:

- (a) Python, R, Excel (Google Sheets) のどれかを使う.
- (b) 確率分布表を参照する.

例題: SAT スコア

SAT スコアは正規モデル $N(\mu = 1100, \sigma = 200)$ によって近似される. 全受験者の中からシャノンが無作為に抽出された. シャノンのスコアが 1190 以上である確率はいくらか.


例題: SAT スコア

SAT スコアは $N(1100, 200)$ に従っている.

- (a) 95 パーセンタイルにある人の SAT スコアを求めなさい.
- (b) 97.5 パーセンタイルにある人の SAT スコアを求めなさい.

68:95:99.7 ルール

正規分布において, 平均 ± 1 標準偏差, 2 標準偏差, 3 標準偏差の範囲の確率は以下の図のようになる:



例題: 割合の概算

SAT スコアは平均 $\mu = 1100$ と標準偏差 $\sigma = 200$ の正規分布に従っていると近似できる.

- (a) スコアが 700 から 1500 である受験者は約何パーセントか.
- (b) スコアが 1100 と 1500 の間であるのは約何パーセントか.